

Desafio Técnico - Sistema RAG com Ollama

Contexto

Você foi contratado como desenvolvedor de IA em uma empresa que deseja implementar um sistema inteligente de atendimento ao cliente baseado em documentos internos. A ideia é permitir que os usuários façam perguntas sobre documentos institucionais e recebam respostas contextualizadas geradas por um modelo de linguagem natural.

Seu desafio é construir um sistema funcional de geração aumentada por recuperação (RAG), capaz de indexar documentos, realizar buscas semânticas e gerar respostas usando um modelo local via Ollama. O foco está na aplicação prática, na organização do código e no uso de boas práticas de engenharia de software.

Objetivo

Criar um sistema simples de Pergunta e Resposta (QA) utilizando o paradigma RAG (Retrieval-Augmented Generation). O sistema deve permitir ao usuário fazer perguntas sobre documentos, usando um modelo local via Ollama e banco vetorial.

Requisitos

1. Ingestão de Documentos:
 - Aceitar arquivos `.txt` ou `.md`.
 - Dividir textos em chunks configuráveis.
 - Indexar com FAISS, Chroma, etc.
2. Busca Vetorial:
 - Buscar chunks semanticamente relevantes.
3. Integração com Ollama:
 - Usar modelo local (ex: llama2, mistral).
 - Concatenar contexto + pergunta no prompt.
4. Interface:

Desafio Técnico - Sistema RAG com Ollama

- CLI ou API simples.

Modelos recomendados via Ollama

Modelos leves que funcionam em CPU:

- mistral
- llama2:7b
- gemma:2b

Ollama roda em CPU! Não requer GPU. Exige ~8-16GB de RAM. Ver: <https://ollama.com/library>

Tempo Estimado

3 a 6 horas.

Entrega Esperada

- Repositório (Git ou zip)
- README com instruções
- Exemplo de pergunta
- (Opcional) Docker, Makefile, vídeo

Alternativa sem GPU

Pode usar API pública (OpenAI, Together.ai). Modularize o código. Documente essa escolha.